Dokumentácia testovania detekcie AI-generovaného hlasu

Účel dokumentácie: zaznamenať testované modely, dáta, postup experimentov, výsledky a obmedzenia. Dokument vychádza z uskutočnených experimentov v Google Colabe.

1. Cieľ testovania

Cieľom bolo overiť, do akej miery dokážu modely automaticky rozlíšiť autentickú ľudskú reč (REAL, bonafide) od syntetického alebo upraveného hlasu (FAKE, spoof). Testovanie sa sústredilo na kvalitu klasifikácie, schopnosť rozlišovať triedy pri rôznych prahoch a prenositeľnosť medzi tromi odlišnými datasetmi.

2. Použité dáta

Dataset	REAL	FAKE	Spolu	Charakteristika
Dataset1	21	21	42	Dlhšie nahrávky, často niekoľko minút
Dataset2	20	60	80	Pôvodné a syntetické nahrávky; rôzne formáty
Dataset3	423	431	854	Rozsiahlejší súbor, rôzne dĺžky
Spolu	464	512	976	Tri samostatné testovacie súbory

Dataset1: označenie tried vychádzalo z adresárov Fake/Real.

Dataset2: súbory original.* predstavovali REAL, súbory synthetic_*.mp3 predstavovali FAKE; obsahoval skupiny UK/USA, male/female a rôznych hovoriacich. Obsahoval taktiež WAV, MP3 aj M4A. Pri niektorých M4A súboroch knižnica librosa prešla na alternatívne načítanie cez audioread; výpočet sa dokončil.

Dataset3: označenie vychádzalo z názvov a priečinkov real_*/fake_*. Tento dataset mal najväčší podiel dát (854 z 976), preto výrazne ovplyvňuje spoločné metriky.

3. Modely a prostredie

Predtrénovaný DF Arena 1B

Testovaný model: Speech-Arena-2025/DF_Arena_1B_V_1. Načítaval sa pomocou transformers.pipeline s úlohou antispoofing.

Prostredie: Google Colab, GPU NVIDIA Tesla T4; v zaznamenanom behu PyTorch 2.11.0+cu130 a Transformers 5.18.0. Zvuk sa načítal pomocou librosa.load(path, sr=16000, mono=True), teda mono pri 16 kHz.

4. Postup základného testovania

- Rozbalenie datasetov z archívov Google Drive do pracovného priečinka Colabu.
- Zostavenie zoznamu súborov a pravdivých tried REAL/FAKE podľa štruktúry datasetu.
- Načítanie celej zvukovej nahrávky, prevod na mono 16 kHz.
- Spustenie predtrénovaného modelu na celej nahrávke (whole-file inference).
- Uloženie skóre spoof pre každý súbor a klasifikácia FAKE pri skóre ≥ 0,5, inak REAL.
- Výpočet metrík samostatne pre každý dataset a následne na spojenej množine.
- Uloženie individuálnych skóre a súhrnu do CSV súborov na Google Drive.

Základné výsledky DF Arena vznikli bez dodatočného trénovania modelu na týchto troch datasetoch (zero-shot test). Celkovo bolo spracovaných 976/976 súborov bez chýb inferencie.

5. Vyhodnocovacie metriky

Accuracy vyjadruje podiel správnych predikcií. Balanced Accuracy (BA) je priemer citlivosti oboch tried a zohľadňuje nerovnomerné zastúpenie REAL/FAKE. FAKE recall je podiel správne zachytených falošných hlasov; REAL recall je podiel správne rozpoznaných autentických hlasov. Precision a F1 opisujú kvalitu predikcií triedy FAKE. ROC AUC hodnotí schopnosť zoradiť REAL a FAKE bez voľby konkrétneho thresholdu.

Konfúzna matica používa FAKE ako pozitívnu triedu: TP = správne FAKE, TN = správne REAL, FP = REAL označené ako FAKE, FN = FAKE označené ako REAL.

6. Výsledky DF Arena pri thresholde 0,5

Dataset	Accuracy	BA	ROC AUC	FAKE recall	REAL recall
Dataset1	64,29 %	64,29 %	0,9138	33,33 %	95,24 %
Dataset2	87,50 %	78,33 %	0,9108	96,67 %	60,00 %
Dataset3	88,88 %	88,81 %	0,9591	96,29 %	81,32 %
Spolu	87,70 %	87,39 %	0,9484	93,75 %	81,03 %

Dataset	TN	FP	FN	TP
Dataset1	20	1	14	7
Dataset2	12	8	2	58
Dataset3	344	79	16	415

Interpretácia: Dataset1 mal vysokú ROC AUC, ale pri prahu 0,5 zachytil iba 7 z 21 FAKE nahrávok. To ukazuje, že dobré poradie skóre automaticky neznamená vhodne nastavený rozhodovací prah. Dataset2 a Dataset3 dosiahli vysoký FAKE recall, ale vykazovali viac falošných poplachov pri REAL.

7. Experiment so segmentovaním

Skúšala sa alternatíva, pri ktorej sa nahrávky delili na približne 4,037-sekundové úseky (64 600 vzoriek pri 16 kHz), s krokom približne 2,019 s (50 % prekrytie). Pre každý segment sa vypočítalo spoof skóre a pre celú nahrávku sa porovnával priemer, medián, 90. percentil (P90), maximum a podiel segmentov so skóre ≥ 0,5.

Pilotný test zahŕňal 9 vybraných súborov: 6 z Dataset1 a 3 problémové REAL z Dataset3. Napríklad pri FAKE Recording (16).wav z Dataset1 kleslo skóre z whole-file 0,8281 na priemer segmentov 0,1734. Pri REAL real_038.wav z Dataset3 zostalo skóre veľmi vysoké (whole-file 0,9998; priemer segmentov 0,9990).

Záver: segmentovanie v tejto konfigurácii nepreukázalo konzistentné zlepšenie a nebolo zavedené do zvolenej základnej detekčnej logiky. Pilotná vzorka 9 súborov však nestačí na definitívny záver o všetkých možných spôsoboch segmentovania.

8. Experiment s rozhodovacou hranicou

Na uložených whole-file skóre sa testovali prahy od 0,05 do 0,95 s krokom 0,005. Výber bol založený na maximálnej priemernej Balanced Accuracy troch datasetov, pričom každý dataset mal rovnakú váhu.

Metrika	Threshold 0,500	Threshold 0,360
Priemerná BA datasetov	77,14 %	80,12 %
Spoločná BA	87,39 %	84,74 %
Spoločná accuracy	87,70 %	85,35 %
FAKE recall	93,75 %	97,07 %
REAL recall	81,03 %	72,41 %

Prahová hodnota 0,360 bola najlepšia podľa zvoleného vývojového kritéria. Na Dataset1 dosiahla BA 83,33 %, na Dataset2 71,67 % a na Dataset3 85,36 %. Zlepšila záchyt FAKE, no znížila schopnosť rozpoznávať REAL. Prah 0,360 je preto vývojovo kalibrovaný, nie nezávisle overený na nových dátach.

9. Záver a obmedzenia

- Najsilnejší testovaný predtrénovaný základ predstavoval DF Arena 1B.
- Výsledky sú závislé od datasetu aj rozhodovacej hranice.
- Spoločné metriky sú dominované Dataset3; preto sa vyhodnocovali aj jednotlivé datasety a ich rovnako vážený priemer.
- Optimalizácia threshold a diagnostika chýb prebehli na dostupných testovacích dátach.
- Experiment so segmentovaním bol iba pilotný a nepokrýval všetkých 976 nahrávok.

11. Reprodukovateľné výstupy a odkazy

Model: https://huggingface.co/Speech-Arena-2025/DF_Arena_1B_V_1

Dataset1: https://www.kaggle.com/datasets/kambingbersayaphitam/speech-dataset-of-human-and-ai-generated-voices

Dataset2: https://www.kaggle.com/datasets/unidpro/real-vs-fake-human-voice-deepfake-audio

Dataset3: https://www.kaggle.com/datasets/pawarrohitashok/fake-and-real-audio-dataset-deepfake-data